Advanced Materials of Python

Yung-Chin Yen

April 6, 2020

Outline

1 Python 套件管理 4
- 1.1 pip v.s. conda . . . 4
  - 1.1.1 pip or conda . . . 4
  - 1.1.2 pip . . . 4
  - 1.1.3 conda . . . 4
  - 1.1.4 In both cases: . . . 4
  - 1.1.5 difference between conda, anaconda, and miniconda . . . 4
- 1.2 conda 安裝與使用 . . . 5
  - 1.2.1 下載 v.s. 安裝 . . . 5
  - 1.2.2 常見 conda 指令 . . . 5
- 1.3 Python 常用函式庫 . . . 5
  - 1.3.1 爬蟲 . . . 5
  - 1.3.2 網站 . . . 5
  - 1.3.3 資料處理科學計算 . . . 6
  - 1.3.4 視覺化 . . . 6
  - 1.3.5 機器學習 . . . 6
  - 1.3.6 地圖學/地圖視覺化 . . . 6
  - 1.3.7 ArcGIS . . . 6
- 1.4 python package 安裝 (conda) . . . 6
- 1.5 python 執行環境建立與維護 . . . 7

2 Numpy 模組 8
- 2.1 Numpy . . . 8
- 2.2 匯入模組 . . . 8
- 2.3 Create ndarray . . . 8
  - 2.3.1 一維陣列 . . . 8
  - 2.3.2 二維陣列 . . . 9
  - 2.3.3 多維陣列 . . . 9

2.3.4 隨機矩陣 10

3 Matplotlib 11
3.1 Matplotlib 簡介 11
3.2 折線圖 11
3.2.1 基本語法 11
3.2.2 練習 #1：繪製折線圖 11
3.2.3 圖形美化: plot() function 12
3.2.4 練習 #2：圖表美化 15
3.3 bar chart: plt.bar() 15
3.4 pie chart: plt.pie() 15
3.4.1 語法： 15
3.4.2 參數： 15
3.4.3 範例 15
3.5 其它圖表 16
3.6 文字註解: plt.text() 16
3.6.1 語法 16
3.6.2 範例 16
3.7 子圖表: plt.subplot() 17

4 區域資料檔分析 20
4.1 Excel/CSV: Pandas 模組 20
4.1.1 CSV 20
4.1.2 Pandas 20
4.1.3 Pandas 資料結構 20
4.2 Pandas functions 21
4.2.1 資料選取 21
4.2.2 條件式選取資料 24
4.3 進階分析 25
4.3.1 計算: Aggregation, Groupby 25
4.3.2 資料檔下載: `scores.csv` 27
4.4 資料視覺化 27
4.4.1 Bar chart 27
4.4.2 Pie chart 27
4.4.3 Scatter chart 28
4.4.4 Line chart 29

5 網路爬蟲 31
5.1 parse JSON 31
5.1.1 What is JSON? 31

5.1.2 JSON 的優點 31
5.1.3 JSON 結構 32
5.1.4 實作 1: 國際主要國家貨幣每月匯率概況 32
5.1.5 實作 2: 澎湖生活博物館每月參觀人次統計資料 34
5.1.6 實作 3: 下載 JSON 36
5.1.7 實作: 解析 JSON 38
5.1.8 練習 39
5.2 parse HTML 39
5.2.1 所需套件 39
5.3 範例: 以程式抓取 PTT 電影板 header 39
5.3.1 原則 39
5.3.2 實作: 取得 HTML 資料 39
5.3.3 實作：解析 HTML 資料內容 40

6 如何把 python 程式 publish 成網站應用程式 43

1 Python 套件管理

1.1 pip v.s. conda

1.1.1 pip or conda

- Python 的一大優勢之一便是龐大的第三方函式庫，讓使用 python 的程式設計師可以方便的呼叫、進行如網路資料下載解析、資料的視覺化、甚或是大數據的複雜分析與人工智慧的相關套件。,
- 目前用來管理這些龐大套件的工具主要有二：pip 與 Conda。

1.1.2 pip

- Pip 是Python Packaging Authority推薦、用於從Python Package Index安裝套件的工具，提供了對 Python 套件的搜尋、下載、安裝、卸載的功能。
- 若在 python.org 下載最新版本的 python，則已內建 pip 安裝套件。Python 3.4+ 以上版本均已包括 pip
- 該工具類似 Linux 下的 apt/yum 或 MAC 下的Homebrew。

1.1.3 conda

- Conda 是一個開源的跨平台工具軟體，它被設計作為 Python、R、Lua、Scala 與 Java 等任何程式語言的套件、依賴性以及工作環境管理員，特別受到以 Python 作為主要程式語言的資料科學團隊所喜愛。
- 傳統 Python 使用者以 pip 作為套件管理員（package manager）、以 venv 作為工作環境管理員（environment manager），而 conda 則達成了「兩個願望、一次滿足」既可以管理套件亦能夠管理工作環境。[1]

1.1.4 In both cases:

- Written in Python
- Open source (Conda is BSD and pip is MIT)

1.1.5 difference between conda, anaconda, and miniconda

- conda is both a command line tool, and a python package. [2]
- Anaconda 發行版會預裝很多 pydata 生態圈裡的軟件，而 Miniconda 是最小的 conda 安裝環境，一個乾淨的 conda 環境。
- pip 只是運與安裝 python package，而 conda 用來安裝管理任何語言的包。
- 不一定要安裝 Anaconda 或 Miniconda，也可透過 pip 直接安裝 conda

```
pip install conda
```

[1] 輕鬆學習 Python：conda 的核心功能

[2] What are the differences between Conda nd Anaconda?

1.2 conda 安裝與使用

1.2.1 下載 v.s. 安裝

- Anaconda
- Miniconda

1.2.2 常見 conda 指令

- `conda --version` : 檢視 conda 版本
- `conda update PACKAGE_NAME` : 更新指定套件
- `conda --help` : 檢視 conda 指令說明文件
- `conda list` : 檢視目前工作環境安裝的套件清單
- `conda list --ENVIRMOMENT` : 檢視指定工作環境安裝的套件清單
- `conda install PACKAGE_NAME=Version` : 在目前的工作環境安裝指定套件
- `conda remove PACKAGE_NAME` : 在目前的工作環境移除指定套件
- `conda create --name ENVIRMOMENT python=Version` : 建立新的工作環境且安裝指定 Python 版本
- `conda activate ENVIRONMENT` : 切換至指定工作環境
- `conda deactivate` : 回到 base 工作環境
- `conda env export --name ENVIRMOMENT --file ENVIRMOMENT.yml` : 將指定工作環境之設定匯出為.yml 檔藉此複製且重現工作環境

1.3 Python 常用函式庫

1.3.1 爬蟲

- Scrapy: 舉世聞名，分散式爬蟲框架，不僅僅是簡單的庫
- beautifulsoup4: Beautiful Soup 是一個可以從 HTML 或 XML 文件中提取數據的 Python 庫.[3]
- urllib/urllib2: urllib is a package that collects several modules for working with URLs
- selenium: Selenium 原為網頁測試工具，但由於可以直接以程式碼操控瀏覽器的特性，使其成為網路爬蟲必備的工具之一。[4]

1.3.2 網站

- Django: 重量級網頁框架
- Flask: 輕量級網頁框架

[3] Python 爬蟲解析庫——BeautifulSoup4

[4] python 網路爬蟲教學-Selenium 基本操作

1.3.3 資料處理科學計算

- Numpy: 陣列矩陣神器
- Scipy: 科學計算神器
- Pandas

1.3.4 視覺化

- matplotlib: matlab 風格式的套件
- seaborn: 散點圖矩陣神器
- ggplot: R 語言視覺化神器的 Python 版本
- plotly: 這個神器是個 js 庫，不過也有各種流行的語言介面

1.3.5 機器學習

- scikit-learn: 幾乎所有機器學習演算法都囊括
- NLTK: 自然語言處理工具套件
- Theano/TensorFlow/Keras: 深度學習套件
- PyTorch: Numpy 的 GPU 版

1.3.6 地圖學/地圖視覺化

- basemap/cartopy: 畫地圖的 package
- Folium: leaflet 的 Python 版本
- GDAL: 開源 GIS package
- geocoder: 地理編碼神器
- geopandas: 地理資料的熊貓套件
- PySAL: 空間計量經濟學的一個神套件

1.3.7 ArcGIS

- arcpy: ArcGIS 內嵌 Python 的神器，可以非常方便呼叫 ArcGIS 各項功能，但是有一點就是不開源（畢竟人家是商業軟體嘛，所以那些老想著在自己安裝的 Python 上 import arcpy 的同學可以省省
- ArcGIS API for Python: 基於 portal 和 online 的一套 API，還是有些可以玩的價值，後面也會考慮介紹這個內容。

1.4 python package 安裝 (conda)

- 安裝 package: **`conda install packageName`**

```
conda install pandas
```

- 移除 package: **`conda remove packageName`**

```
conda remove pandas
```

- 安裝特定版本 python **conda install python=version**

```
conda install python=3.5
```

- 了解目前系統可用套件

```
  conda list
```

1.5 python 執行環境建立與維護

- 建立[5]

```
conda create -n envName
```

- 啟用

```
  source activate envName
```

- 退出

```
  source deactiveate
```

- 刪除

```
  conda env remove -n envName
```

- 列出目前系統中所有的虛擬環境

```
  conda env list
```

[5] Day01 Anaconda 環境安裝!

2 Numpy 模組

2.1 Numpy

- Numpy 是 Python 的一個重要模組，主要用於資料處理上。Numpy 底層以 C 和 Fortran 語言實作，所以能快速操作多重維度的陣列。[6]
- 當 Python 處理龐大資料時，其原生 list 效能表現並不理想（但可以動態存異質資料），而 Numpy 具備平行處理的能力，可以將操作動作一次套用在大型陣列上。
- Python 其餘重量級的資料科學相關套件（例如：Pandas、SciPy、Scikit-learn 等）都幾乎是奠基在 Numpy 的基礎上。因此學會 Numpy 對於往後學習其他資料科學相關套件打好堅實的基礎。

2.2 匯入模組

- 使用模組裡的函式要加模組名稱

```
import numpy
```

- 匯入 numpy 模組並使用 np 作為簡寫，這是 Numpy 官方倡導的寫法

```
import numpy as np
```

- Numpy 中的多維資料型別稱為 ndarray

2.3 Create ndarray

- Numpy 的重點在於陣列的操作，其所有功能特色都建築在同質且多重維度的 ndarray（N-dimensional array）上。
- ndarray 的關鍵屬性是維度（ndim）、形狀（shape）和數值類型（dtype）。一般我們稱一維陣列為 vector 而二維陣列為 matrix[6]。

2.3.1 一維陣列

- list 或 tuple 轉入

```
import numpy as np
np1 = np.array( [1, 2, 3, 4] )
print(np1)
```

```
[1 2 3 4]
```

- 使用 np.arange( ) 方法

[6] 從零開始學資料科學：Numpy 基礎入門

```
import numpy as np
np2 = np.arange(5)
print(np2)
```

```
[0 1 2 3 4]
```

2.3.2 二維陣列

```
import numpy as np
np4 = np.array( [[1, 2, 4], [3,4,5]])
print("np4:\n", np4)

np5 = np.array([np.arange(3), np.arange(3)])
print('np5:\n', np5)

np6 = np.arange(8).reshape(2, 4)
print('np6:\n', np6)
```

```
np4:
 [[1 2 4]
 [3 4 5]]
np5:
 [[0 1 2]
 [0 1 2]]
np6:
 [[0 1 2 3]
 [4 5 6 7]]
```

2.3.3 多維陣列

```
import numpy as np

np7 = np.arange(24).reshape(2, 3, 4)
print('np7:\n',np7)
```

```
np7:
 [[[ 0  1  2  3]
  [ 4  5  6  7]
  [ 8  9 10 11]]
```

```
 [[12 13 14 15]
  [16 17 18 19]
  [20 21 22 23]]]
```

2.3.4 隨機矩陣

```python
import numpy as np

np8 = np.random.random((3, 2)) #矩陣大小以tuple表示
print('np8:\n', np8)

np9 = np.random.randint(0, 100, size=[4, 3]) #矩陣大小以list表示
print('np9:\n', np9)
```

```
np8:
 [[0.25790607 0.49465406]
 [0.22828345 0.77978968]
 [0.00990244 0.71363209]]
np9:
 [[82 72 39]
 [72 51 84]
 [96 75 59]
 [33 40 99]]
```

3 Matplotlib

3.1 Matplotlib 簡介

- NumPy 的可視化操作界面
- 為 Python 最多人使用的 2D 繪圖工具
- 優點：圖形美觀、類型多、相容於 Matlab
- 官方社群網站 https://matplotlib.org/
- 維基百科 https://zh.wikipedia.org/wiki/Matplotlib

3.2 折線圖

3.2.1 基本語法

- import matplotlib.pyplot as plt
- plt.plot( ) 函式為 matplotlib.pyplot 模組畫線條方法，其語法如下

```
plt.plot( [x座標資料,] y座標資料 [, 參數1, 參數2, ...] )
```

- np.sin( ) 函式為 Numpy 模組求正弦值
- plt.show( ) 函式用來顯示圖形

```
import matplotlib.pyplot as plt
import numpy as np

x = np.arange(-3, 3, 0.01)
plt.clf()
plt.plot(x, np.sin(x))
# for web-based: plt.show()

plt.savefig('SimpleSin.png', dpi=300)
```

3.2.2 練習 #1：繪製折線圖

- 利用 list 繪製
  - x1 = [1, 2, 3, 4, 5, 6]
  - y1 = [1, 2, 3, 4, 5, 6]
- 執行 plt.plot(y1) 和 plt.plot(x1, y1) 有何差別??
- 利用 numpy 繪製
  - x2 = np.arange(0, 3, 0.01)
- 執行 plt.plot(x2, x2**2) 看看畫出什麼圖形??

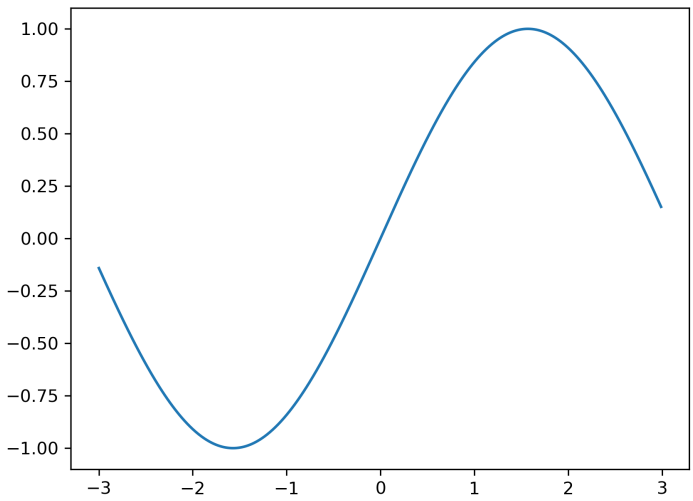

Figure 1: 簡單的 sin 圖形

3.2.3 圖形美化: plot() function

1. plot() 函式參數可分為兩類：fmt 字串和 kwarg 參數
   - fmt 定義基本格式：顏色、標記、線條樣式
   - kwarg 為 Line2D 屬性 (參考資料)：color, linestyle, marker, label, linewidth, ⋯.
   - 若 fmt 和 kwarg 設定衝突時，以 kwarg 為主
   - plot(): fmt 字串

字元	顏色	字元	標記	字元	標記
'b'	藍	'.'	點	'*'	*
'g'	綠	'o'	圓圈	'+'	+
'r'	紅	'v'	三角形 (下)	'x'	x
'c'	青	'^'	三角形 (上)	'd'	鑽石
'm'	洋紅	'<'	三角形 (左)	字元	線條
'y'	黃	'>'	三角形 (右)	'-'	實線
'k'	黑	's'	正方形	'–'/':'	虛線
'w'	白	'p'	五邊形	'-.'	-.-.-.-.

2. kwgarg 參數
   - colorg
     - 單字，如 g：color = 'lime'
     - 字母，如 g：color = 'k'
     - 色碼，如 g：color = '#FF0000'
     - RGB 值 (0~g1 之間)，如：color = (1, 0, 0)
   - label：g 呈現線條標籤，如 label = 'y = x^2'
     - 需搭配 pglt.legend() 函式方能呈現 label

3. 色彩對照

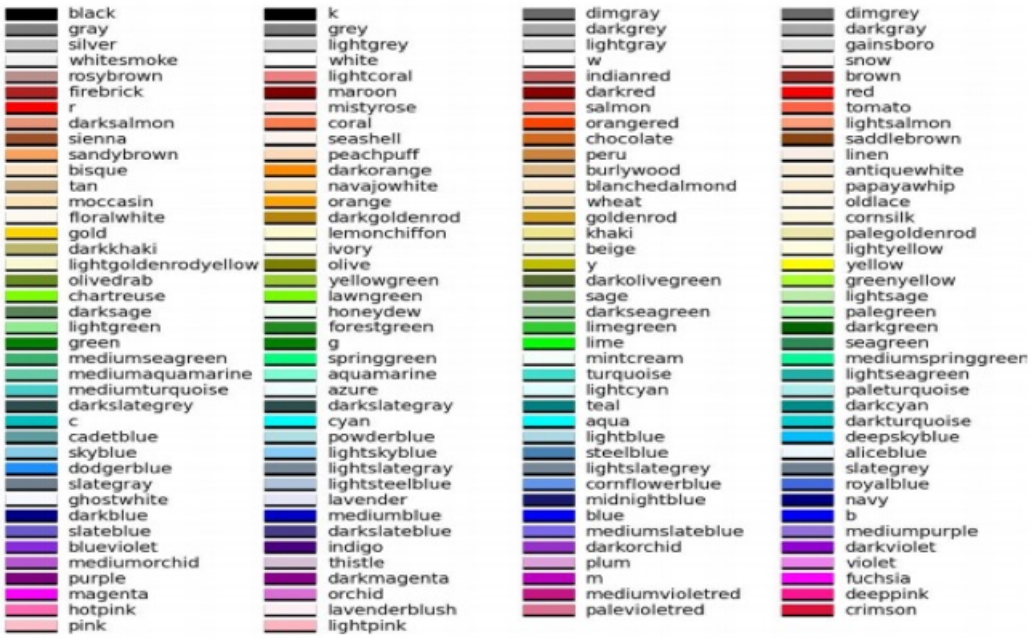

Figure 2: 色表

4. 折線示範 #1

```
import matplotlib.pyplot as plt
import numpy as np

x1 = [1, 2, 3, 4, 5, 6]
y1 = [1, 2, 3, 4, 5, 6]
plt.clf()
plt.plot(x1, y1, color='c', linestyle='-', marker='p')
plt.savefig('line1.png', dpi=300)
```

5. 折線示範 #2

```
import matplotlib.pyplot as plt
import numpy as np

x1 = [1, 2, 3, 4, 5, 6]
y1 = [1, 2, 3, 4, 5, 6]
x2 = np.arange(0, 3, 0.01)
x3 = np.arange(8).reshape(2, 4)

plt.plot(y1, 'c-p', x2, x2**2, x3, x3+3, '-*')
plt.savefig('line2.png', dpi=300)
```

6. 其他參數
   - x / y 座標範圍：plt.xlim(起始值, 終止值) / plt.ylim(起, 止)

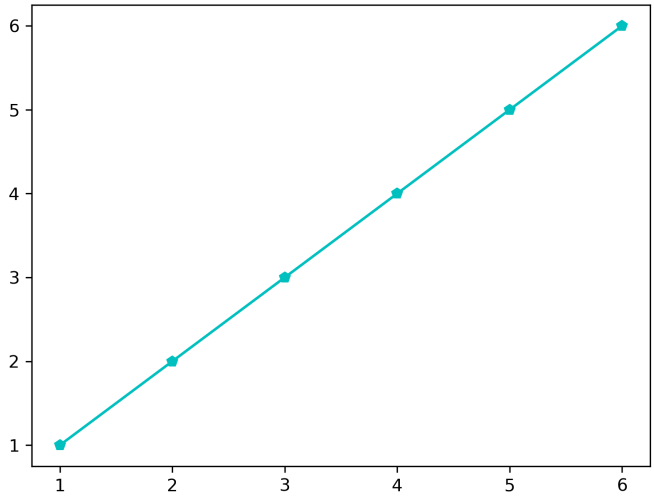

Figure 3: 簡單的折線圖形 #1

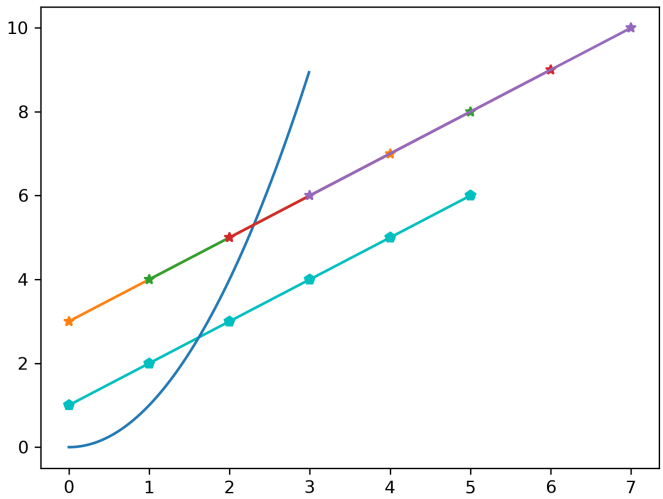

Figure 4: 簡單的折線圖形 2

- 圖表標題：plt.title(字串)
- x / y 座標標題：plt.xlabel(字串) / plt.ylabel(字串)
- 顯示 kwarg 參數裡的 label：plt.legend()

3.2.4 練習 #2：圖表美化

1. 將??的圖表加上標記、線條標籤，換線條顏色、線條樣式
2. 請將下列資料繪成折線圖 (男女折線不同顏色、樣式，加標記)

初婚年齡	2006	2011	2014	2015	2016
男	30.7	31.8	32.1	32.2	32.4
女	27.8	29.4	29.9	30.0	30.0

- 圖表標題: Age of first marriage
- 座標軸標題: x Year、y Age
- 線條標籤: 男 Male、女 Female

3.3 bar chart: plt.bar()

- 語法 `plt.bar( x座標資料, y座標資料 [, 參數1, 參數2, ...] )`
- 練習 #3: 請將??的男女初婚年齡改成長條圖

3.4 pie chart: plt.pie()

3.4.1 語法：

plt.pie(比例列表 [, 參數 1, 參數 2, . . .])

3.4.2 參數：

- colors：各子圖顏色，多以 list 表示
- labels：各子圖標籤，多以 list 表示
- explode：各子圖分離突出比例，0.1 代表分離 10%，多以 list 表示
- autopct：顯示各子圖比例值，格式為%x.y%%
- startangle：繪製起始角度，預設為 0 (與三角函數角度相同)
- 若要以正圓形繪製，請再加上 plt.axis('equal')

3.4.3 範例

```
import matplotlib.pyplot as plt
import numpy as np

parts = [35.35, 23, 26.65, 15]
labels = ['Harrison', 'Vanessa', 'James', 'Ruby']
```

```
colors = ['red', 'lightblue', 'purple', 'yellow']
explodes = [0.1, 0, 0, 0.1]
plt.pie(parts, colors = colors, labels = labels, explode = explodes,
    autopct = '%3.2f%%')
plt.axis('equal')
plt.legend()

#plt.show()
plt.savefig('simplePie.png', dpi=300)
```

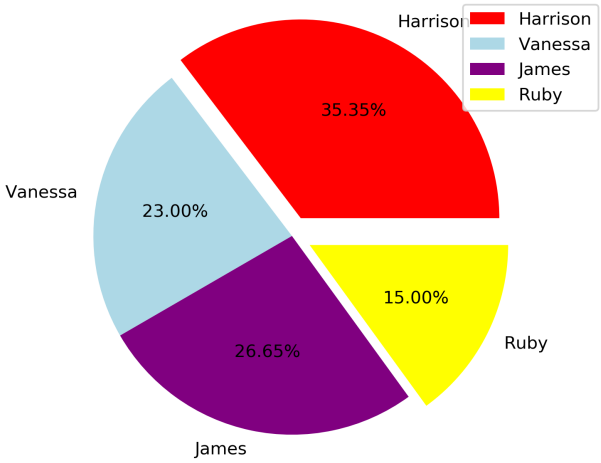

Figure 5: 簡單的 pie chart

3.5 其它圖表

- 直方圖 (Histogram)：用來呈現各資料統計結果 (參考資料)
- 散佈圖 (Scatter)：用來呈現群聚關係 (參考資料)
- 進階學習資源

3.6 文字註解: plt.text()

3.6.1 語法

- `plt.text( x相對座標, y相對座標 , 文字字串 [, 其它參數] )`
- 參考資料

3.6.2 範例

```
import matplotlib.pyplot as plt

x = [1, 2, 3, 4, 5, 6, 7, 8]
y = [1, 4, 9, 16, 25, 36, 49, 64]
plt.plot(x, y, 'r--')
for x, y in zip(x, y):
    plt.text(x-0.2, y+0.6, '(%d, %d)' %(x, y))
#plt.show()
plt.savefig('simpleText.png', dpi = 300)
```

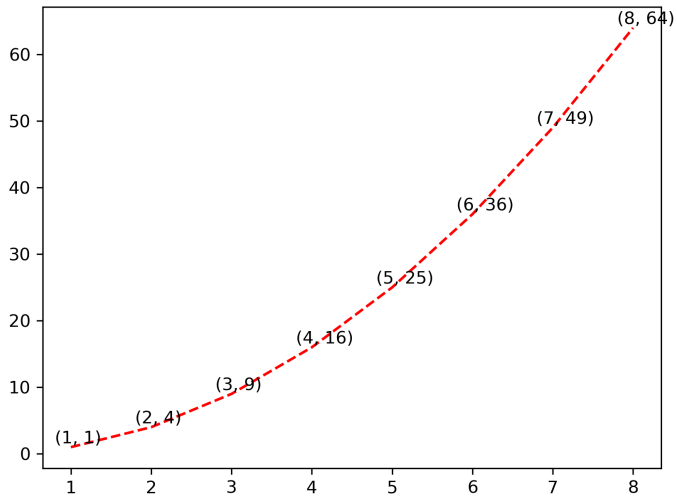

Figure 6: 簡單的文字註解

3.7 子圖表: plt.subplot()

- 範例[7]

```
import numpy as np
import matplotlib.pyplot as plt

from matplotlib.ticker import NullFormatter  # useful for `logit` scale

# Fixing random state for reproducibility
np.random.seed(19680801)

# make up some data in the interval ]0, 1[
y = np.random.normal(loc=0.5, scale=0.4, size=1000)
```

[7] matplotlib.pyplot.subplot

```
y = y[(y > 0) & (y < 1)]
y.sort()
x = np.arange(len(y))

# plot with various axes scales
plt.figure()

# linear
plt.subplot(221)
plt.plot(x, y)
plt.yscale('linear')
plt.title('linear')
plt.grid(True)


# log
plt.subplot(222)
plt.plot(x, y)
plt.yscale('log')
plt.title('log')
plt.grid(True)


# symmetric log
plt.subplot(223)
plt.plot(x, y - y.mean())
plt.yscale('symlog', linthreshy=0.01)
plt.title('symlog')
plt.grid(True)

# logit
plt.subplot(224)
plt.plot(x, y)
plt.yscale('logit')
plt.title('logit')
plt.grid(True)
# Format the minor tick labels of the y-axis into empty strings with
# `NullFormatter`, to avoid cumbering the axis with too many labels.
plt.gca().yaxis.set_minor_formatter(NullFormatter())
# Adjust the subplot layout, because the logit one may take more space
# than usual, due to y-tick labels like "1 - 10^{-3}"
```

```
plt.subplots_adjust(top=0.92, bottom=0.08, left=0.10, right=0.95, hspace=0.25,
                    wspace=0.35)

plt.savefig('simpleSubplot.png', dpi = 300)
```

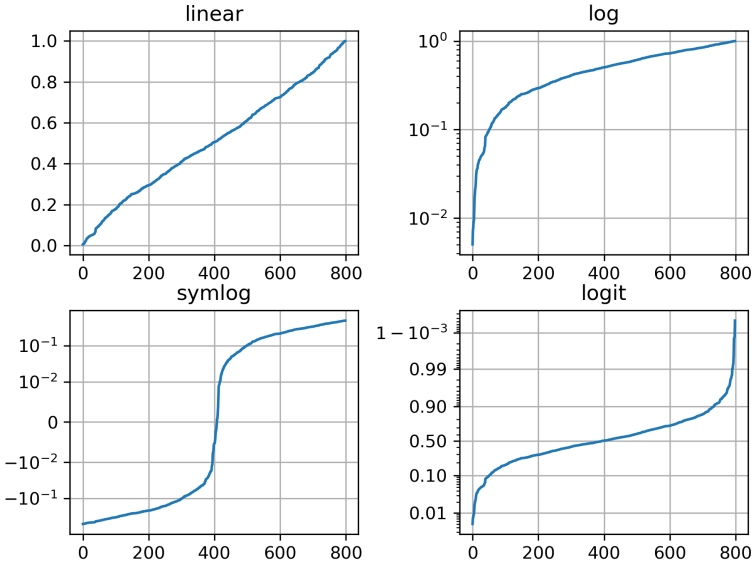

Figure 7: 簡單的子圖表

- 參考資料

4 區域資料檔分析

4.1 Excel/CSV: Pandas 模組

4.1.1 CSV

- 為純文字檔，以逗號分隔值（Comma-Separated Values，CSV，有時也稱為字元分隔值，因為分隔字元也可以不是逗號）。
- 純文字意味著該檔案是一個字元序列，不含必須像二進位制數字那樣被解讀的資料。
- CSV 檔案由任意數目的記錄組成，記錄間以某種換行符分隔；每條記錄由欄位組成，欄位間的分隔符是其它字元或字串，最常見的是逗號或製表符。通常，所有記錄都有完全相同的欄位序列[2]。

4.1.2 Pandas

- Pandas 是 python 的一個數據分析模組，2009 年底開源出來，提供高效能、簡易使用的資料格式 (Data Frame) 讓使用者可以快速操作及分析資料。
- Pandas 強化了資料處理的方便性也能與處理網頁資料與資料庫資料等，有點類似於 Office 的 Excel 能更加方便的進行運算、分析等[8]。
- Pandas 主要特色有[5]：
  1. 在異質數據的讀取、轉換和處理上，都讓分析人員更容易處理，例如：從列欄試算表中找到想要的值。
  2. Pandas 提供兩種主要的資料結構，Series 與 DataFrame。Series 顧名思義就是用來處理時間序列相關的資料 (如感測器資料等)，主要為建立索引的一維陣列。DataFrame 則是用來處理結構化 (Table like) 的資料，有列索引與欄標籤的二維資料集，例如關聯式資料庫、CSV 等等。
  3. 透過載入至 Pandas 的資料結構物件後，可以透過結構化物件所提供的方法，來快速地進行資料的前處理，如資料補值，空值去除或取代等。
  4. 更多的輸入來源及輸出整合性，例如：可以從資料庫讀取資料進入 Dataframe，也可將處理完的資料存回資料庫。

4.1.3 Pandas 資料結構

- Pandas 是 Python 的資料分析函式庫，從 2009 年底開放原始碼，提供簡易使用的資料結構和分析工具，讓分析人員可以快速方便的處理結構化資料。
- 要使用 Pandas 之前，先瞭解兩個主要資料結構[1]：
  - Series: 是一維標籤陣列（array），能夠保存任何資料類型（整數、字符串、浮點數等）。
  - DataFrame: 是一個二維標籤資料結構，可以具有不同類型的行 (column)，類似 Excel 的資料表，對於有使用過統計軟體的分析人員應該不陌生。
  - 簡單來說，Series 可以想像為一行多列（row）的資料，而 DataFrame 是多行多列的資料，藉由選擇索引（列標籤）和行（行標籤）的參數來操作資料，就像使用統計軟體透過樣本編

[8] conda、miniconda、anaconda 的區別以及在 pycharm 中選擇 conda 的虛擬環境

號或變項名稱來操作資料。

4.2 Pandas functions

4.2.1 資料選取

1. Select as dictinoary (column): [9]
   - `df[[[['col1', 'col2']]]]`
   - `df.col1`
   - 下載範例檔:scores.csv

```python
import pandas as pd

# 讀取csv
df = pd.read_csv("scores.csv")

# colum
print(df.id)
print(df[['id', 'typing']])
```

```
Pandas version: 0.25.1
0      201910901
1      201910902
2      201910903
3      201910904
4      201910905
         ...
207    201911726
208    201911727
209    201911728
210    201911729
211    201911730
Name: id, Length: 212, dtype: int64
            id  typing
0    201910901      72
1    201910902      56
2    201910903      76
3    201910904      64
4    201910905      56
..         ...     ...
```

[9] Python 讀寫 csv 檔案的幾種方法及 pandas.read$_{csv}$ 引數全解

```
207  201911726      80
208  201911727      60
209  201911728      48
210  201911729      84
211  201911730      72

[212 rows x 2 columns]
```

2. Select using index (row):
   - **df[1:20]**

```python
import pandas as pd

df = pd.read_csv("scores.csv")

print(df[1:3])
print(df[df.homework<30])
```

```
          id  classparti  typing  homework  midexam  finalexam
1  201910902          96      56     93.42     60.0       40.0
2  201910903          96      76    102.63     45.0       28.0
            id  classparti  typing  homework  midexam  finalexam
10   201910911          62      44     20.39      4.0        0.0
18   201910919          14      56     25.92      0.0        0.0
23   201910924          75      48     10.75      0.0        0.0
124  201911315          71     120     15.35      0.0        0.0
140  201911331          93     120     25.88      0.0       16.0
0      False
1      False
2      False
3      False
4      False
       ...
207    False
208    False
209    False
210    False
211    False
Name: homework, Length: 212, dtype: bool
```

3. loc, iloc, between [10]

[10] Day23- 資料處理模組-Pandas 介紹

- loc: 基於行標籤和列標籤（x_{label}、y_{label}）進行索引，以 column 名做為 index
- iloc: 基於行索引和列索引（index，columns）都是從 0 開始，以數字做為 index
- between: 檢查區間值，`Series.between(self, left, right, inclusive=True)`

(a) 範例 1

```python
import pandas as pd

df = pd.read_csv("scores.csv")

print(df.loc[df.homework<25, ['id', 'homework']])
print(df.iloc[:5, 2:5])
```

```
             id  homework
10   201910911     20.39
23   201910924     10.75
124  201911315     15.35
   typing  homework  midexam
0      72     92.11     48.0
1      56     93.42     60.0
2      76    102.63     45.0
3      64     86.84     44.0
4      56     42.11      0.0
```

(b) 範例 2

```python
# 載入函式庫
import pandas as pd

print("Pandas version:", pd.__version__)
# 讀取csv
df = pd.read_csv("scores.csv")
# 輸出前3筆
print(df.iloc[:3])
# 輸出前3筆的第2,3欄
print(df.iloc[:2, 1:3])
# 輸出第3筆user的homework成績
print(df.loc[2,'homework'])

print(df['midexam'].between(50, 60))
midFilter = df['midexam'].between(50, 55)
print(df[midFilter])
```

```
Pandas version: 0.25.1
          id  classparti  typing  homework  midexam  finalexam
0  201910901         100      72     92.11     48.0       16.0
1  201910902          96      56     93.42     60.0       40.0
2  201910903          96      76    102.63     45.0       28.0
   classparti  typing
0         100      72
1          96      56
102.63
0      False
1       True
2      False
3      False
4      False
       ...
207    False
208    False
209    False
210    False
211    False
Name: midexam, Length: 212, dtype: bool
            id  classparti  typing  homework  midexam  finalexam
6    201910907         101     120     92.11     55.0       20.0
65   201911029          93      60     82.00     50.0       16.0
72   201911036          88      80    102.63     53.0       76.0
92   201911119          82     104     89.47     50.0       20.0
94   201911121          95     100     88.51     52.0       72.0
109  201911136          91     100     81.58     51.0        4.0
171  201911626          98      72     97.37     50.0       75.0
```

4.2.2 條件式選取資料

1. 語法
   - **df[(condition)]**
   - **df[(condition 1)& (condition 2)]**
2. 範例

```python
import pandas as pd

df = pd.read_csv("scores.csv")

```

```
print(df[(df.midexam >= 100) & (df.finalexam >= 100)])
```

	id	classparti	typing	homework	midexam	finalexam
11	201910912	87	92	92.11	110.8	103.75
70	201911034	104	92	102.63	100.8	101.00
88	201911115	120	88	105.26	113.5	111.00
98	201911125	119	80	107.89	113.2	115.00
102	201911129	106	52	102.63	103.6	100.00
127	201911318	108	80	102.63	104.8	100.00
138	201911329	105	48	107.89	100.0	100.00
143	201911334	100	120	81.58	104.8	113.00
153	201911608	88	0	102.63	100.0	100.00
169	201911624	82	100	102.63	101.5	105.00
182	201911701	103	108	92.63	100.0	100.00
189	201911708	106	108	102.63	107.2	101.00
190	201911709	108	88	107.89	104.8	105.00
191	201911710	102	100	102.63	100.0	105.00
193	201911712	105	96	101.58	107.5	100.00
195	201911714	102	44	107.89	110.0	110.00
196	201911715	106	120	107.89	102.4	105.00
198	201911717	80	120	107.89	106.0	100.00
201	201911721	109	76	100.00	100.0	100.00
203	201911722	105	120	102.63	101.5	105.00
210	201911729	87	84	105.26	112.3	103.00

4.3 進階分析

4.3.1 計算: Aggregation, Groupby

1. create new column based on other column
2. simple aggregation
3. groupby with aggregation function
4. 範例

```
# 載入函式庫
import pandas as pd

# 讀取csv
df = pd.read_csv("scores.csv")

# 計算總分'
```

```python
df['Final'] = df.classparti*.1 + df.typing*.1 + df.homework*.2 + df.
    midexam*.3 + df.finalexam*.3

# create new column according to typing speed
df.loc[df.typing < 30, 'TypingSpeed' ] = 'LOW'
df.loc[df.typing.between(30, 60), 'TypingSpeed' ] = 'MID'
df.loc[df.typing > 60, 'TypingSpeed' ] = 'HIGH'

print(df)

# 依打字速度分組
print(df.groupby('TypingSpeed')['Final'].mean())

# PASS/FAIL
df.loc[df.Final < 60, 'PASS'] = False
df.loc[df.Final >= 60, 'PASS'] = True

print(df.groupby('PASS')['typing'].mean())
```

```
            id  classparti  typing  ...  finalexam    Final  TypingSpee
0    201910901         100      72  ...       16.0   54.822         HIG
1    201910902          96      56  ...       40.0   63.884          MI
2    201910903          96      76  ...       28.0   59.626         HIG
3    201910904          93      64  ...       25.0   53.768         HIG
4    201910905          93      56  ...       20.0   29.322          MI
..         ...         ...     ...  ...        ...      ...          ..
207  201911726         106      80  ...      103.0   98.976         HIG
208  201911727          82      60  ...      100.0   89.926          MI
209  201911728          83      48  ...       75.0   81.026          MI
210  201911729          87      84  ...      103.0  102.742         HIG
211  201911730          96      72  ...      100.0   94.626         HIG

[212 rows x 8 columns]
TypingSpeed
HIGH    69.977451
LOW     68.517333
MID     64.086303
Name: Final, dtype: float64
PASS
False    77.567568
```

```
True      84.525547
Name: typing, dtype: float64
```

4.3.2 資料檔下載: scores.csv

4.4 資料視覺化

4.4.1 Bar chart

```python
# 載入函式庫
import pandas as pd
import matplotlib.pyplot as plt
# 讀取csv
df = pd.read_csv("scores.csv")

# 計算總分'
df['Final'] = df.classparti*.1 + df.typing*.1 + df.homework*.2 + df.
    midexam*.3 + df.finalexam*.3

# create new column according to typing speed
df.loc[df.typing < 30, 'TypingSpeed' ] = 'Level-1'
df.loc[df.typing.between(30, 60), 'TypingSpeed' ] = 'Level-2'
df.loc[df.typiohong > 60, 'TypingSpeed' ] = 'Level-3'

fig = df.groupby('TypingSpeed')['homework','classparti'].mean().plot(
    kind='bar', title="XXX", rot=0, legend=True)
fig.set_xlabel("Typing Speed")
fig.set_ylabel("score")
savefig = fig.get_figure()
savefig.savefig('pandasPlot1.png', bbox_inches='tight')
```

4.4.2 Pie chart

```python
# 載入函式庫
import pandas as pd
import matplotlib.pyplot as plt
# 讀取csv
df = pd.read_csv("scores.csv")

# 計算總分'
df['Final'] = df.classparti*.1 + df.typing*.1 + df.homework*.2 + df.
    midexam*.3 + df.finalexam*.3
```

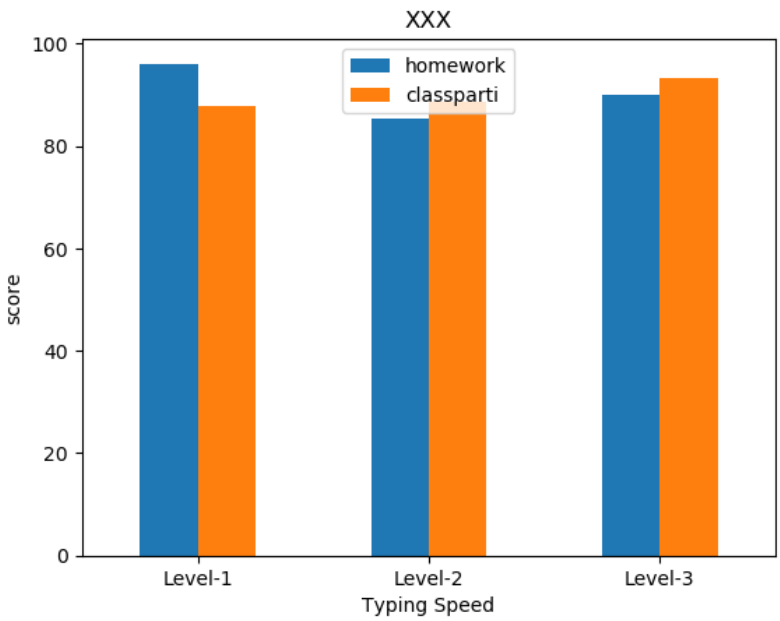

Figure 8: Pandas plot bar chart

```
9
10 # create new column according to typing speed
11 df.loc[df.typing < 60, 'TypingSpeed' ] = 'Level-1'
12 df.loc[df.typing.between(60, 80), 'TypingSpeed' ] = 'Level-2'
13 df.loc[df.typing > 80, 'TypingSpeed' ] = 'Level-3'
14 print(df.groupby('TypingSpeed').count())
15
16 fig = df.groupby('TypingSpeed')['TypingSpeed'].count().plot(kind='pie',
      title="XXX", rot=0, legend=True)
17 savefig = fig.get_figure()
18 savefig.savefig('pandasPlot2.png', bbox_inches='tight')
```

```
              id  classparti  typing  homework  midexam  finalexam  Final
TypingSpeed
Level-1       25          25      25        25       25         25     25
Level-2       86          86      86        86       86         86     86
Level-3      101         101     101       101      100        101    100
```

4.4.3 Scatter chart

```
1 # 載入函式庫
2 import pandas as pd
3 import matplotlib.pyplot as plt
4
```

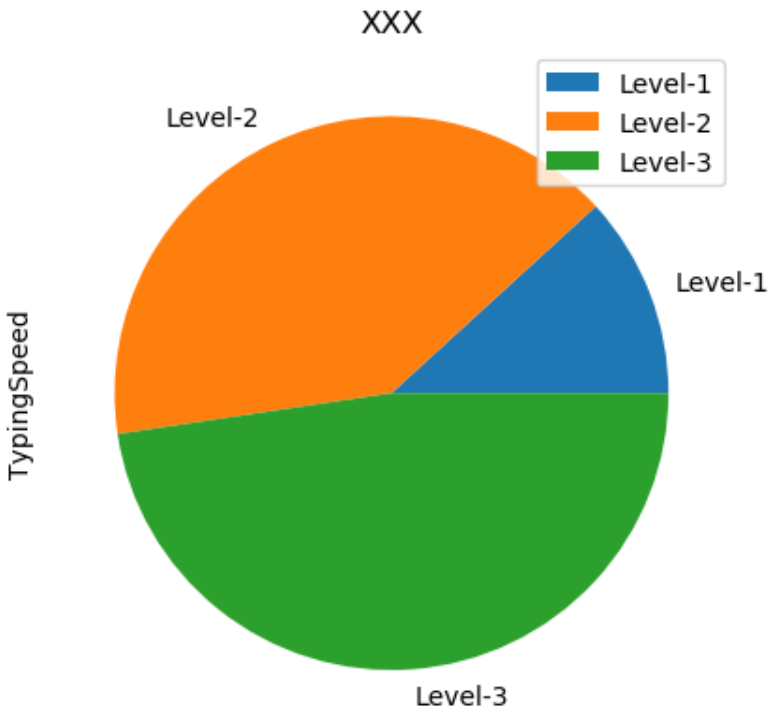

Figure 9: Pandas plot pie chart

```
# 讀取csv
df = pd.read_csv("scores.csv")

fig = df[['typing','homework']].plot(kind='scatter', x=0, y=1)
df[['typing','homework']].plot.line(x=0, y=1)
#fig = df[['typing','finalexam']].plot(kind='scatter', x=0, y=1)

savefig = fig.get_figure()
savefig.savefig('PandasPlot3.png')
```

4.4.4 Line chart

```
# 載入函式庫
import pandas as pd
import matplotlib.pyplot as plt

# 讀取csv
df = pd.read_csv("scores.csv")

fig = df[['midexam','finalexam']].plot(kind='scatter', x=0, y=1)

savefig = fig.get_figure()
```

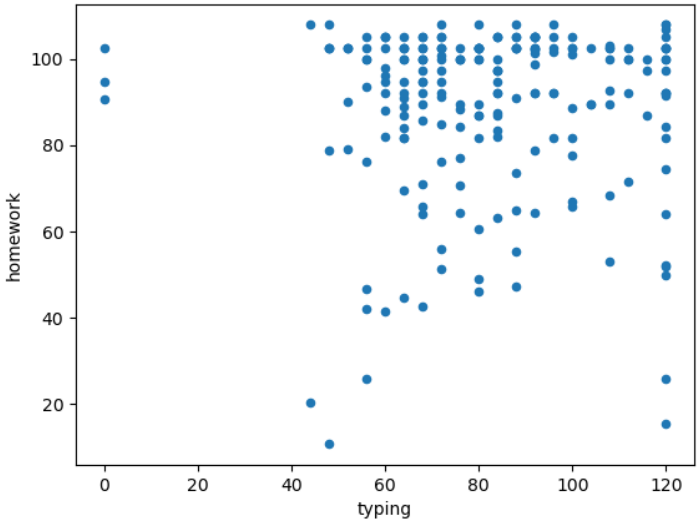

Figure 10: Pandas plot scatter chart

```
savefig.savefig('PandasPlot4.png')
```

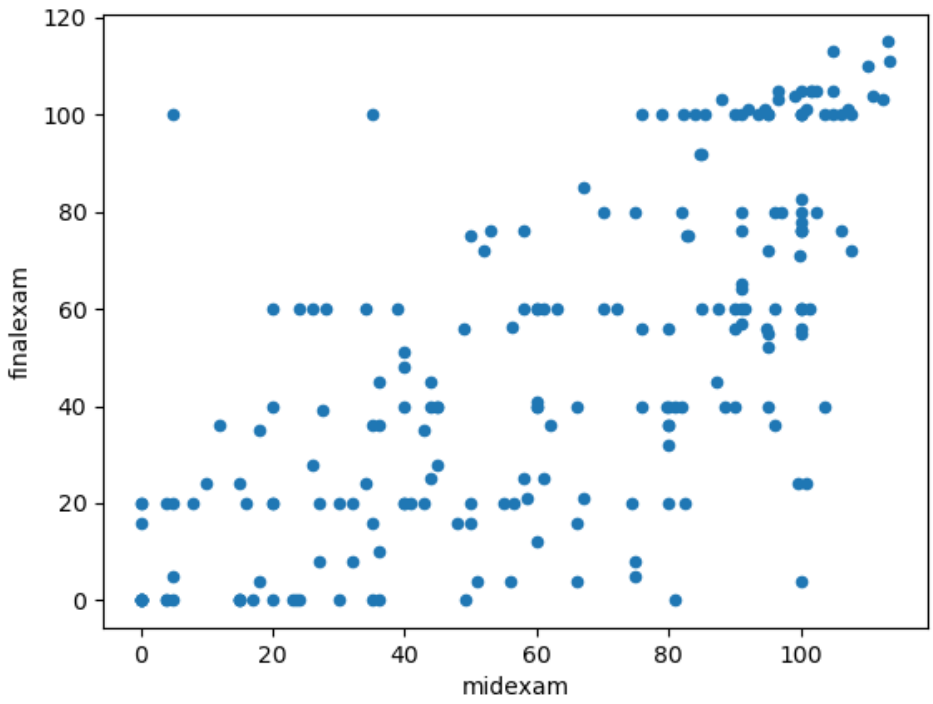

Figure 11: Pandas plot scatter chart

5 網路爬蟲

5.1 parse JSON

5.1.1 What is JSON?

- JSON(JavaScript Object Notation，JavaScript 物件表示法) 是個以純文字為基底去儲存和傳送簡單結構資料，你可以透過特定的格式去儲存任何資料 (字串, 數字, 陣列, 物件)，也可以透過物件或陣列來傳送較複雜的資料。[11]
- 一旦建立了您的 JSON 資料，就可以非常簡單的跟其他程式溝通或交換資料，因為 JSON 就只是純文字個格式。

5.1.2 JSON 的優點

- 相容性高
- 格式容易瞭解，閱讀及修改方便
- 支援許多資料格式 (number,string,booleans,nulls,array,associative array)
- 許多程式都支援函式庫讀取或修改 JSON 資料

[11] 你不可不知的 JSON 基本介紹

5.1.3 JSON 結構

- 物件: {}
- 陣列: []

5.1.4 實作 1: 國際主要國家貨幣每月匯率概況

1. 下載 JSON

```python
import requests

json_url = 'https://quality.data.gov.tw/dq_download_json.php?nid=11339&md5_url=f2fdbc21603c55b11aead08c84184b8f'
response = requests.get(json_url)

jsonRes = response.json()
print(type(jsonRes))
print(jsonRes[:10])
print('日期', ":", '美元／新台幣')
for item in jsonRes:
    print(item['日期'], ":", item['美元／新台幣'])
```

<class 'list'> [{'日期': '2020/2/3', '美元／新台幣': '30.332', '人民幣／新台幣': '4.321461', '歐元／美元': '1.1077', '美元／日幣': '108.535', '英鎊／美元': '1.3147', '澳幣／美元': '0.6695', '美元／港幣': '7.7685', '美元／人民幣': '7.0189', '美元／南非幣': '14.9376', '紐幣／美元': '0.64675'}, {'日期': '2020/2/4', '美元／新台幣': '30.207', '人民幣／新台幣': '4.320537', '歐元／美元': '1.1056', '美元／日幣': '108.945', '英鎊／美元': '1.29605', '澳幣／美元': '0.67185', '美元／港幣': '7.76895', '美元／人民幣': '6.9915', '美元／南非幣': '14.8117', '紐幣／美元': '0.6466'}, {'日期': '2020/2/5', '美元／新台幣': '30.152', '人民幣／新台幣': '4.306248', '歐元／美元': '1.1044', '美元／日幣': '109.345', '英鎊／美元': '1.3046', '澳幣／美元': '0.6741', '美元／港幣': '7.7644', '美元／人民幣': '7.0019', '美元／南非幣': '14.8205', '紐幣／美元': '0.6484'}, {'日期': '2020/2/6', '美元／新台幣': '30.082', '人民幣／新台幣': '4.315112', '歐元／美元': '1.1002', '美元／日幣': '109.905', '英鎊／美元': '1.29915', '澳幣／美元': '0.6751', '美元／港幣': '7.7633', '美元／人民幣': '6.9713', '美元／南非幣': '14.73', '紐幣／美元': '0.6466'}, {'日期': '2020/2/7', '美元／新台幣': '30.126', '人民幣／新台幣': '4.311904', '歐元／美元': '1.09685', '美元／日幣': '109.905', '英鎊／美元': '1.29315', '澳幣／美元': '0.6706', '美元／港幣': '7.76115', '美元／人民幣': '6.9867', '美元／南非幣': '14.9919', '紐幣／美元': '0.64405'}, {'日期': '2020/2/10', '美元／新台幣': '30.102', '人民幣／新台幣': '4.30883', '歐元／美元': '1.0946', '美元／日幣': '109.845', '英鎊／美元': '1.28835', '澳幣／美元': '0.6697', '美元／港幣': '7.76475', '美元／人民幣': '6.9861', '美元／南非幣': '15.014', '紐幣／美元': '0.64075'}, {'日期': '2020/2/11', '美元／新台幣': '30.068', '人民幣／新台幣': '4.307872', '歐元／美

元': '1.0908', ' 美元／日幣': '109.915', ' 英鎊／美元': '1.2897', ' 澳幣／美元': '0.6707', ' 美元／港幣': '7.76335', ' 美元／人民幣': '6.9798', ' 美元／南非幣': '14.92815', ' 紐幣／美元': '0.6385'}, {' 日期': '2020/2/12', ' 美元／新台幣': '30.032', ' 人民幣／新台幣': '4.305388', ' 歐元／美元': '1.0917', ' 美元／日幣': '109.885', ' 英鎊／美元': '1.2969', ' 澳幣／美元': '0.6732', ' 美元／港幣': '7.76805', ' 美元／人民幣': '6.97545', ' 美元／南非幣': '14.78', ' 紐幣／美元': '0.6464'}, {' 日期': '2020/2/13', ' 美元／新台幣': '30.037', ' 人民幣／新台幣': '4.301749', ' 歐元／美元': '1.08805', ' 美元／日幣': '109.735', ' 英鎊／美元': '1.2975', ' 澳幣／美元': '0.67255', ' 美元／港幣': '7.76855', ' 美元／人民幣': '6.9825', ' 美元／南非幣': '14.96025', ' 紐幣／美元': '0.64555'}, {' 日期': '2020/2/14', ' 美元／新台幣': '30.051', ' 人民幣／新台幣': '4.301741', ' 歐元／美元': '1.08345', ' 美元／日幣': '109.775', ' 英鎊／美元': '1.3052', ' 澳幣／美元': '0.67255', ' 美元／港幣': '7.7672', ' 美元／人民幣': '6.9858', ' 美元／南非幣': '14.88945', ' 紐幣／美元': '0.6434'}] 日期: 美元／新台幣 2020/2/3 : 30.332 2020/2/4 : 30.207 2020/2/5 : 30.152 2020/2/6 : 30.082 2020/2/7 : 30.126 2020/2/10 : 30.102 2020/2/11 : 30.068 2020/2/12 : 30.032 2020/2/13 : 30.037 2020/2/14 : 30.051 2020/2/17 : 30.056 2020/2/18 : 30.125 2020/2/19 : 30.152 2020/2/20 : 30.254 2020/2/21 : 30.403 2020/2/24 : 30.472 2020/2/25 : 30.402 2020/2/26 : 30.383 2020/2/27 : 30.33 2020/3/2 : 30.124 2020/3/3 : 30.087 2020/3/4 : 30.038 2020/3/5 : 29.96 2020/3/6 : 30.04 2020/3/9 : 30.13 2020/3/10 : 30.036 2020/3/11 : 30.095 2020/3/12 : 30.15 2020/3/13 : 30.21 2020/3/16 : 30.22 2020/3/17 : 30.25 2020/3/18 : 30.276 2020/3/19 : 30.506 2020/3/20 : 30.302 2020/3/23 : 30.405 2020/3/24 : 30.316 2020/3/25 : 30.325 2020/3/26 : 30.306

2. 資料視覺化

```
import requests
import pandas as pd
json_url = 'https://quality.data.gov.tw/dq_download_json.php?nid
    =11339&md5_url=f2fdbc21603c55b11aead08c84184b8f'
response = requests.get(json_url)
jsonRes = response.json()

dates = [i['日期'] for i in jsonRes]
NTUS = [float(i['美元／新台幣']) for i in jsonRes]
df = pd.DataFrame({'日期':dates, '美元/新台幣':NTUS})

import matplotlib.pyplot as plt

plt.clf()
plt.plot(df['日期'], NTUS)
plt.xticks(rotation=60, fontsize=6)
##plt.plot(dates, JPY)
##plt.plot(dates, EUR)
```

```
plt.savefig('jsonLine.png', dpi=300)
```

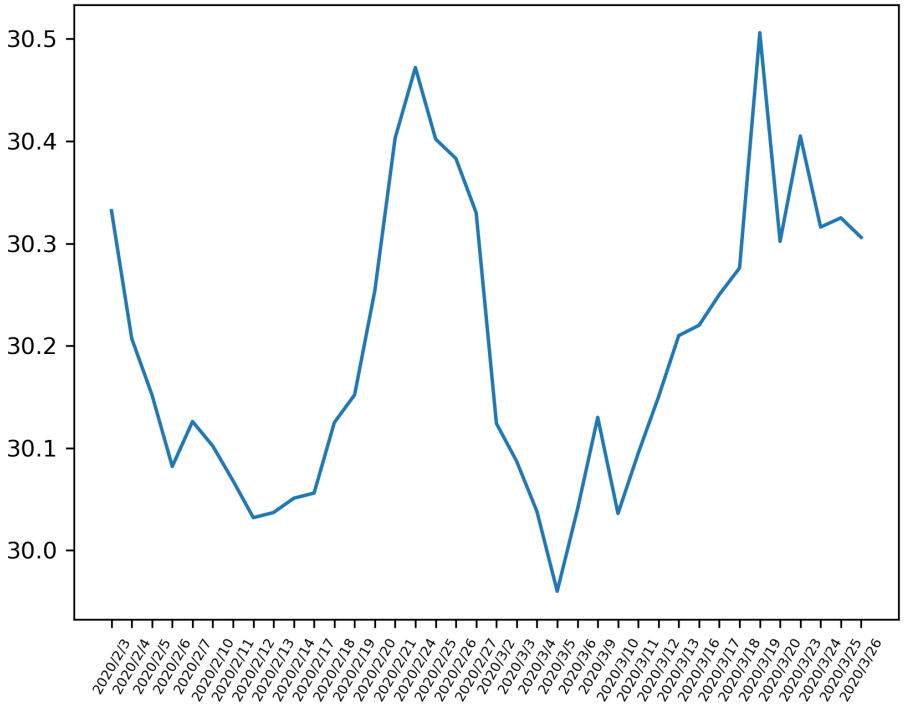

Figure 12: 匯率

5.1.5 實作 2: 澎湖生活博物館每月參觀人次統計資料

1. 中文亂碼處理
   - Python-MacOS 上 matplotlib 顯示中文字體
   - 關於 python：Matplotlib 使刻度標籤字體更小
2. DEMO

```
#coding:utf-8
import requests
import pandas as pd
from datetime import datetime

json_url = 'http://opendataap2.penghu.gov.tw/resource/files
    /2020-01-12/eaa641fc3af66277e60b13201ca11232.json'

response = requests.get(json_url)
jsonRes = response.json()

year = [i['年度'] for i in jsonRes]
month = [i['月份'] for i in jsonRes]
```

```
visitor = [int(i['人數']) for i in jsonRes]

df = pd.DataFrame({'year':year, 'month':month, 'visitor':visitor
    })
df['date'] = [str(int(i)+1911)+'-'+j for i, j in zip(df['year'],
     df['month'])]

df['time'] = [pd.to_datetime(i, format='%y%m', errors='ignore')
    for i in df['date']]

import matplotlib.pyplot as plt
plt.rcParams['font.family'] = 'cwTeXFangSong'
plt.clf()
plt.bar(df['date'], df['visitor'])
plt.xticks(rotation=60, fontsize=6)
plt.ylabel('人數')
plt.xlabel('日期')
plt.title('澎湖生活博物館每月參觀人次')
plt.savefig('jsonBar.png', dpi=300, bbox_inches='tight')
```

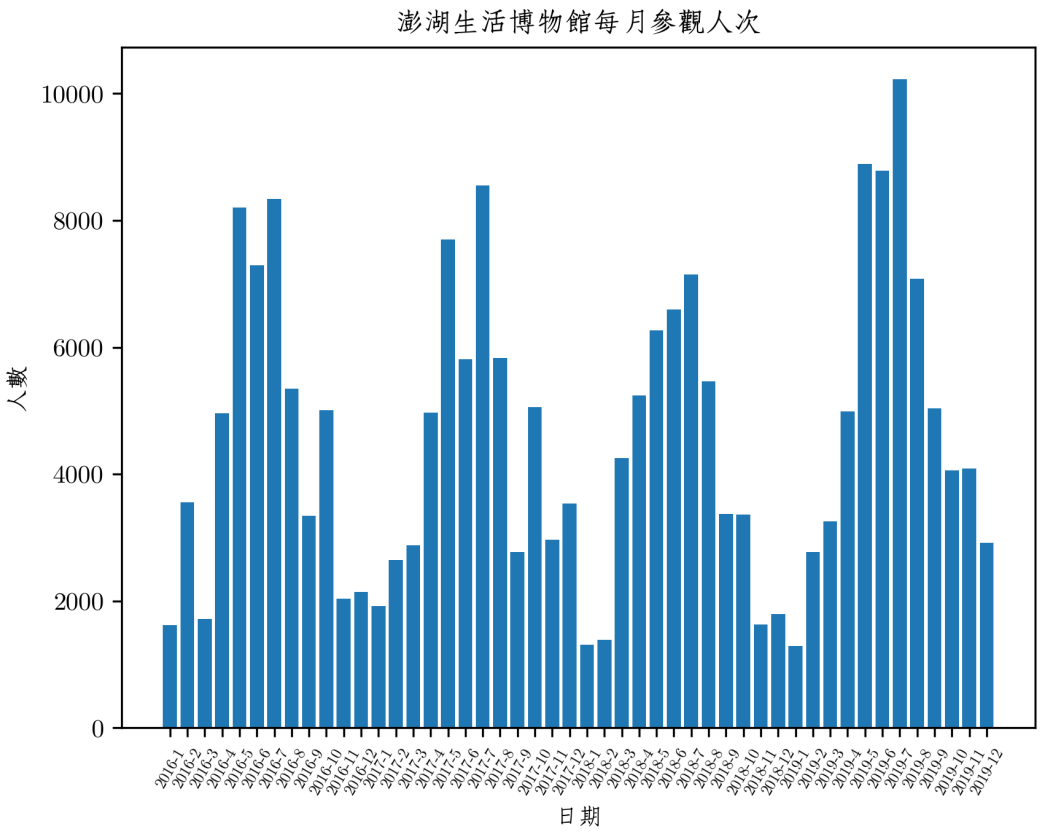

Figure 13: 參觀人數

5.1.6 實作 3: 下載 JSON

```
import requests
import json
json_url = 'http://www.kh.edu.tw/json/bulletin/employ/datagrid?page=1&
    rows=20'
response = requests.get(json_url)

print(response)
# 方法1
jsonRes1 = response.json()
print(type(jsonRes1))
#
jsonRes2 = json.loads(response.text)
print(type(jsonRes2))

print(jsonRes2)
```

<Response [200]> <class 'dict'> <class 'dict'> {'total': 20, 'rows': [{'author': '加昌國小', 'attributes': {'subjects': '閩南語', 'url': 'https://employ.kh.edu.tw/Html/2020/4/楠梓區 108 學年度加昌國小第 3 號第 14 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度加昌國小第 3 號第 14 次公告', 'pubDate': '109-04-03'}, {'author': '加昌國小', 'attributes': {'subjects': '普通科', 'url': 'https://employ.kh.edu.tw/Html/2020/4/楠梓區 108 學年度加昌國小第 10 號第 1 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度加昌國小第 10 號第 1 次公告', 'pubDate': '109-04-03'}, {'author': '瑞祥高中', 'attributes': {'subjects': '', 'url': 'https://employ.kh.edu.tw/Html/2020/4/前鎮區 108 學年度瑞祥高中第 9 號第 1 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度瑞祥高中第 9 號第 1 次公告', 'pubDate': '109-04-01'}, {'author': '鼓山高中', 'attributes': {'subjects': '', 'url': 'https://employ.kh.edu.tw/Html/2020/4/鼓山區 108 學年度鼓山高中第 11 號第 2 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度鼓山高中第 11 號第 2 次公告', 'pubDate': '109-04-01'}, {'author': '橫山國小', 'attributes': {'subjects': '特殊教育（身心障礙類）不分類巡迴輔導班', 'url': 'https://employ.kh.edu.tw/Html/2020/4/燕巢區 108 學年度橫山國小第 7 號第 1 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度橫山國小第 7 號第 1 次公告', 'pubDate': '109-04-01'}, {'author': '陽明國小', 'attributes': {'subjects': '自然科', 'url': 'https://employ.kh.edu.tw/Html/2020/3/三民區 108 學年度陽明國小第 7 號第 3 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度陽明國小第 7 號第 3 次公告', 'pubDate': '109-03-31'}, {'author': '巴楠花部落中小學', 'attributes': {'subjects': '', 'url': 'https://employ.kh.edu.tw/Html/2020/3/杉林區 108 學年度巴楠花部落中小學第 13 號第 6 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度巴楠花部落中小學第 13 號第 6 次公告', 'pubDate': '109-03-31'}, {'author': '林園高中', 'attributes': {'subjects': '表演藝術', 'url': 'https://employ.kh.edu.tw/Html/2020/3/林園區

108 學年度林園高中第 18 號第 1 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度林園高中第 18 號第 1 次公告', 'pubDate': '109-03-31'}, {'author': ' 小港國小', 'attributes': {'subjects': ' 健康與體適能科', 'url': 'https://employ.kh.edu.tw/Html/2020/3/小港區 108 學年度小港國小第 14 號第 3 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度小港國小第 14 號第 3 次公告', 'pubDate': '109-03-31'}, {'author': ' 新民國小', 'attributes': {'subjects': ' 普通科代理 (須代導師)', 'url': 'https://employ.kh.edu.tw/Html/2020/3/左營區 108 學年度新民國小第 9 號第 1 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度新民國小第 9 號第 1 次公告', 'pubDate': '109-03-31'}, {'author': ' 鳳雄國小', 'attributes': {'subjects': ' 普通科', 'url': 'https://employ.kh.edu.tw/Html/2020/3/燕巢區 108 學年度鳳雄國小第 2 號第 2 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度鳳雄國小第 2 號第 2 次公告', 'pubDate': '109-03-31'}, {'author': ' 龍華國中', 'attributes': {'subjects': ' 輔導活動', 'url': 'https://employ.kh.edu.tw/Html/2020/3/左營區 108 學年度龍華國中第 12 號第 1 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度龍華國中第 12 號第 1 次公告', 'pubDate': '109-03-31'}, {'author': ' 燕巢國中', 'attributes': {'subjects': ' 資訊科技科 (電腦科)', 'url': 'https://employ.kh.edu.tw/Html/2020/3/燕巢區 108 學年度燕巢國中第 14 號第 2 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度燕巢國中第 14 號第 2 次公告', 'pubDate': '109-03-30'}, {'author': ' 蔡文國小', 'attributes': {'subjects': ' 普通科', 'url': 'https://employ.kh.edu.tw/Html/2020/3/路竹區 108 學年度蔡文國小第 6 號第 3 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度蔡文國小第 6 號第 3 次公告', 'pubDate': '109-03-27'}, {'author': ' 橋頭國中', 'attributes': {'subjects': ' 專任輔導', 'url': 'https://employ.kh.edu.tw/Html/2020/3/橋頭區 108 學年度橋頭國中第 6 號第 3 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度橋頭國中第 6 號第 3 次公告', 'pubDate': '109-03-27'}, {'author': ' 七賢國中', 'attributes': {'subjects': ' 體育', 'url': 'https://employ.kh.edu.tw/Html/2020/3/鼓山區 108 學年度七賢國中第 10 號第 1 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度七賢國中第 10 號第 1 次公告', 'pubDate': '109-03-26'}, {'author': ' 七賢國小', 'attributes': {'subjects': ' 雙語實驗計畫英語專長', 'url': 'https://employ.kh.edu.tw/Html/2020/3/新興區 108 學年度七賢國小第 5 號第 4 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度七賢國小第 5 號第 4 次公告', 'pubDate': '109-03-26'}, {'author': ' 文府國小', 'attributes': {'subjects': '', 'url': 'https://employ.kh.edu.tw/Html/2020/3/左營區 108 學年度文府國小第 5 號第 1 次公告第 1 次修正簡章.html', 'target': '_blank'}, 'title': '108 學年度文府國小第 5 號第 1 次公告第 1 次修正', 'pubDate': '109-03-24'}, {'author': ' 蚵寮國小', 'attributes': {'subjects': '', 'url': 'https://employ.kh.edu.tw/Html/2020/3/梓官區 108 學年度蚵寮國小第 4 號第 1 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度蚵寮國小第 4 號第 1 次公告', 'pubDate': '109-03-23'}, {'author': ' 高雄高工', 'attributes': {'subjects': '', 'url': 'https://employ.kh.edu.tw/Html/2020/3/三民區 108 學年度高雄高工第 3 號第 1 次公告簡章.html', 'target': '_blank'}, 'title': '108 學年度高雄高工第 3 號第 1 次公告', 'pubDate': '109-03-20'}]}

5.1.7 實作: 解析 JSON

```
import requests
import json

response = requests.get('http://www.kh.edu.tw/json/bulletin/employ/datagrid?page=1&rows=20')
jsonRes = response.json()
#print(jsonRes['rows'])
for item in jsonRes['rows']:
    print(item['author'], ":", item['title'],"/", item['pubDate'],"\n")
    sortJR = jsonRes['rows']
    print(type(sortJR))

sortJR.sort(key=lambda x: x['author'], reverse=False)
for item in sortJR:
    print(item['author'], ":", item['title'],"/", item['pubDate'])
```

文德國小: 108 學年度文德國小第 5 號第 3 次公告 / 109-03-12 興仁國中: 108 學年度興仁國中第 8 號第 1 次公告 / 109-03-12 燕巢國中: 108 學年度燕巢國中第 13 號第 2 次公告 / 109-03-12 登發國小: 108 學年度登發國小第 3 號第 2 次公告 / 109-03-11 青年國中: 108 學年度青年國中第 13 號第 1 次公告 / 109-03-10 龍華國中: 108 學年度龍華國中第 11 號第 1 次公告 / 109-03-10 鼓山高中: 108 學年度鼓山高中第 11 號第 1 次公告 / 109-03-10 烏林國小: 108 學年度烏林國小第 3 號第 2 次公告 / 109-03-10 七賢國中: 108 學年度七賢國中第 9 號第 2 次公告 / 109-03-09 溪埔國中: 108 學年度溪埔國中第 7 號第 2 次公告 / 109-03-09 楠梓國中: 108 學年度楠梓國中第 8 號第 4 次公告 / 109-03-09 甲仙國中: 108 學年度甲仙國中第 5 號第 2 次公告 / 109-03-09 立志高中: 108 學年度立志高中第 1 號第 1 次公告 / 109-03-06 阿蓮國小: 108 學年度阿蓮國小第 12 號第 3 次公告 / 109-03-06 金潭國小: 108 學年度金潭國小第 6 號第 3 次公告 / 109-03-06 中崙國中: 108 學年度中崙國中第 7 號第 3 次公告 / 109-03-05 巴楠花部落中小學: 108 學年度巴楠花部落中小學第 14 號第 3 次公告 / 109-03-04 中山國小: 108 學年度中山國小第 10 號第 2 次公告 / 109-03-03 福誠高中: 108 學年度福誠高中第 19 號第 3 次公告 / 109-03-03 彌陀國小: 108 學年度彌陀國小第 5 號第 1 次公告 / 109-03-03 <class 'list'> 七賢國中: 108 學年度七賢國中第 9 號第 2 次公告 / 109-03-09 中山國小: 108 學年度中山國小第 10 號第 2 次公告 / 109-03-03 中崙國中: 108 學年度中崙國中第 7 號第 3 次公告 / 109-03-05 巴楠花部落中小學: 108 學年度巴楠花部落中小學第 14 號第 3 次公告 / 109-03-04 彌陀國小: 108 學年度彌陀國小第 5 號第 1 次公告 / 109-03-03 文德國小: 108 學年度文德國小第 5 號第 3 次公告 / 109-03-12 楠梓國中: 108 學年度楠梓國中第 8 號第 4 次公告 / 109-03-09 溪埔國中: 108 學年度溪埔國中第 7 號第 2 次公告 / 109-03-09 烏林國小: 108 學年度烏林國小第 3 號第 2 次公告 / 109-03-10 燕巢國中: 108 學年度燕巢國中第 13 號第 2 次公告 / 109-03-12 甲仙國中: 108 學年度甲仙國中第 5 號第 2 次公告 / 109-03-09 登發國小: 108 學年度登發國小第 3 號第 2 次公告 / 109-03-11 福誠高中: 108 學年度福誠高中第 19 號第 3 次公告 / 109-03-03 立志高中: 108 學年度立志高中第 1 號第 1 次公告 / 109-03-06 興仁國中: 108 學年度興仁國中第 8 號第 1 次公

告 / 109-03-12 金潭國小: 108 學年度金潭國小第 6 號第 3 次公告 / 109-03-06 阿蓮國小: 108 學年度阿蓮國小第 12 號第 3 次公告 / 109-03-06 青年國中: 108 學年度青年國中第 13 號第 1 次公告 / 109-03-10 鼓山高中: 108 學年度鼓山高中第 11 號第 1 次公告 / 109-03-10 龍華國中: 108 學年度龍華國中第 11 號第 1 次公告 / 109-03-10

5.1.8 練習

- 以程式抓取高雄市政府資料開放平台的線上 JSON 資料，parse 並輸出所需結果

5.2 parse HTML

- what is HTML
- 精神：將程式模仿成一般 user

5.2.1 所需套件

- BeautifulSoup
- 安裝：pip install beautifulsoup4

5.3 範例: 以程式抓取 PTT 電影板 header

5.3.1 原則

1. 要抓網路資料，就要先仔細觀察網頁內容
2. 要儘量欺騙網站自己是 browser

5.3.2 實作: 取得 HTML 資料

1. 第一版

```
# 抓取PTT電影版header
import urllib.request as req
url = "https://www.ptt.cc/bbs/Stock/index.html"

with req.urlopen(url) as response:
    data = response.read().decode("utf-8")
print(data)
```

```
urllib.error.HTTPError: HTTP Error 403: Forbidden
```

被拒絕原因：這隻程式的行為不像一般使用者，被網站伺服器拒絕。403 Forbidden 是 HTTP 協議中的一個 HTTP 狀態碼（Status Code）。可以簡單的理解為沒有權限訪問此站，服務器收到請求但拒絕提供服務[12]。

[12] Anaconda、Miniconda、Conda、pip 的相互關係 (轉載)

2. 第二版: 加入 header

```
import urllib.request as req
url = "https://www.ptt.cc/bbs/Stock/index.html"
# 幫request加上一個header
request = req.Request(url, headers = {
    "User-Agent":"Mozilla/5.0 (Macintosh; Intel Mac OS X 10.14; rv
        :72.0) Gecko/20100101 Firefox/72.0"
})

with req.urlopen(request) as response:
    data = response.read().decode("utf-8")
print('所取得的資料型態: ',type(data))
print(data[700:1200])
```

所取得的資料型態: <class 'str'> api.js'></script></head> <body>
  <a id="logo"
href="bbs"> 批踢踢實業坊 </a> › <a class="board" href="/bbs/Stock/inde
class="board-label"> 看板 Stock</a> <a class="right small" href="/about.html">
關於我們 </a> <a class="right small" href="/contact.html"> 聯絡資訊 </a>

<div class="btn-group bt

5.3.3 實作: 解析 HTML 資料內容

1. 安裝解析 HTML 所需套件

```
pip install beautifulsoup4
```

```
| Requirement | already | satisfied: | beautifulsoup4 | in | /Users/let
| Requirement | already | satisfied: | soupsieve>=1.2 | in | /Users/let
```

2. 第三版: 解析 HTML

```
import urllib.request as req
url = "https://www.ptt.cc/bbs/Stock/index.html"
# 幫request加上一個header
request = req.Request(url, headers = {
    "User-Agent":"Mozilla/5.0 (Macintosh; Intel Mac OS X 10.14; rv
        :72.0) Gecko/20100101 Firefox/72.0"
})

with req.urlopen(request) as response:
```

```
    data = response.read().decode("utf-8")

import bs4
root = bs4.BeautifulSoup(data,"html.parser")

titles = root.find("div", class_="title")
titles = root.find_all("div", class_="title")

for title in titles:
    if title.a != None:
        print(title.a.string)
```

```
[請益] 股市經典圖準嗎?
[請益] 布蘭特和西德州原油差異和淨值更新
Re: [新聞] 慘! 無薪假人數飆到7916人 創8年新高
Re: [新聞] 一桶原油驚見「賣負5元」! 全球儲油空間快爆滿 生產商倒
[標的]防疫概念股 大同2371
[請益] 股票還在高檔是否已反應疫情快結束?
[創作] 陳嘉偉 江偉 (改林俊傑 江南)
[心得] 日本是領先指標
Re: [心得] 日本是領先指標
Re: [新聞] 國際油價又崩跌回到25美元 川普推文只有
[心得] 美國非農數據 + 3月失業率
[標的] 中租-KY(5871)
請問UWT怎麼沒開盤了?
[公告] 精華區導覽Q&A
[公告] Stock 板規V2.6 (2019/06/20)
[公告] 版規修正
[閒聊] 2020/04/01 盤後閒聊
```

3. 第四版: 解析 HTML

```
import urllib.request as req
url = "https://huodalife.pixnet.net/blog/"
# 幫request加上一個header
request = req.Request(url, headers = {
    "User-Agent":"Mozilla/5.0 (Macintosh; Intel Mac OS X 10.14; rv
        :72.0) Gecko/20100101 Firefox/72.0"
})

with req.urlopen(request) as response:
    data = response.read().decode("utf-8")
```

```
import bs4
root = bs4.BeautifulSoup(data,"html.parser")

titles = root.find_all("li", class_="title")
pubs = root.find_all("li", class_="publish")
for pub, title in zip(pubs, titles):
    print(pub.span.string,title.a.string)
```

```
Dec  豁達人生選股機－免費開放使用中！
Mar  博智(8155)_強勢型成長股_2019.4Q&2020/02
Mar  月報（2019.3Q&2020/02）－好好思考長期機率的分配
Mar  個股回顧_原相(3227)
Feb  月報_穩定型成長股&強勢型成長股_2019.3Q&2020/01－崩盤起因於過於繁
Jan  豁達人生2019年回顧－報酬率、再論大盤MACD、白銀ETF、傻瓜精神
Jan  原相(3227)_強勢型成長股_2019.3Q&2019/12
Jan  鈺太(6679)_穩定型成長股_2019.3Q&2019/12
Jan  月報_穩定型成長股&強勢型成長股_2019.3Q&2019/12
Jan  個股回顧_博智(8155)
Jan  個股回顧_優群(3217)
Dec  月報_穩定型成長股&強勢型成長股_2019.3Q&2019/11
Nov  博智(8155)_強勢型成長股_2019.3Q&2019/10
Nov  信驊(5274)_穩定型成長股_2019.3Q&2019/10
Nov  優群(3217)_穩定型成長股_2019.3Q&2019/10
```

6 如何把 python 程式 publish 成網站應用程式